

线性代数基础

七月在线 唐博士

2018年3月10日

课程纲要

□ 理论回顾

- 基本概念
- 矩阵计算及性质
- 矩阵微积分

□ 实践讲解——最小二乘法

- 基本引导
- 统计意义
- 几何意义

基本概念

□ 线性代数提供了一种紧凑地表示和操作线性方程组的方法

$$4x_1 - 5x_2 = -13$$

$$-2x_1 + 3x_2 = 9$$



$$A\mathbf{x} = \mathbf{b}$$

$$A = \begin{bmatrix} 4 & -5 \\ -2 & 3 \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad \mathbf{b} = \begin{bmatrix} -13 \\ 9 \end{bmatrix}$$

基本概念

□ 由 m 个方程和 n 个未知变量构成的线性系统可表示为如下形式

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \cdots + a_{2n}x_n = b_2 \\ \cdots \\ a_{m1}x_1 + a_{m2}x_2 + a_{m3}x_3 + \cdots + a_{mn}x_n = b_m \end{cases}$$

a_{ij} 和 b_i 是给定的系数和常数项
 x_j 是待求解的变量

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in R^{m \times n} \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \in R^n \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} \in R^n$$

$$A\mathbf{x} = \mathbf{b}$$

矩阵计算及性质

□ 加法

给定矩阵 $A \in R^{m \times n}$ 和 $B \in R^{m \times n}$ 则

$$A + B = (a_{ij} + b_{ij})_{mn}$$

矩阵 A 与 B 相加就是两个矩阵对应元素相加

矩阵 A 与 B 能够相加的前提是这两个矩阵行列数(或者叫size)相同

□ 数乘

给定实数 $\beta \in R$ 和矩阵 $A \in R^{m \times n}$ 则数乘:

$$\beta A = (\beta a_{ij})_{mn} \quad \text{矩阵} A \text{中每个元素均与 } \beta \text{ 相乘}$$

矩阵计算及性质

□ 向量-向量乘积

■ 内积(inner product)

给定向量 $\mathbf{x}, \mathbf{y} \in R^n$ 则

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x} \cdot \mathbf{y} = \mathbf{x}^T \mathbf{y} = [x_1, x_2, \dots, x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \sum_{j=1}^n x_j y_j$$

■ 外积(outer product)

给定向量 $\mathbf{x} \in R^m, \mathbf{y} \in R^n$ 则

$$\mathbf{x}\mathbf{y}^T = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} [y_1, y_2, \dots, y_n] = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_n y_1 & x_n y_2 & \cdots & x_n y_n \end{bmatrix}$$

矩阵计算及性质

□ 内积及正交性

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle = \mathbf{x} \cdot \mathbf{y} = \mathbf{x} \cdot \mathbf{y} = \mathbf{x}^T \mathbf{y} = \mathbf{y}^T \mathbf{x}$$

$$= [x_1, x_2, \dots, x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = [y_1, y_2, \dots, y_n] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \sum_{j=1}^n x_j y_j$$

$$\langle \lambda \mathbf{x}, \mathbf{y} \rangle = \lambda \langle \mathbf{x}, \mathbf{y} \rangle$$

$$\langle \mathbf{x} + \mathbf{y}, \mathbf{z} \rangle = \langle \mathbf{x}, \mathbf{z} \rangle + \langle \mathbf{y}, \mathbf{z} \rangle$$

$$\langle \mathbf{x}, \mathbf{y} \rangle^2 \leq \langle \mathbf{x}, \mathbf{x} \rangle \langle \mathbf{y}, \mathbf{y} \rangle$$

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq \|\mathbf{x}\| \|\mathbf{y}\|$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos \theta, \quad \theta = \arccos \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

向量 \mathbf{x} 与向量 \mathbf{y} 垂直 $\Leftrightarrow \langle \mathbf{x}, \mathbf{y} \rangle = 0$

如果 n 阶方阵 A 满足 $A^T A = I$ 或 $A^T = A^{-1}$ 方阵 A 称为正交矩阵

矩阵计算及性质

□ 矩阵-向量乘积

给定 $A \in R^{m \times n}$ 和 $\mathbf{x} \in R^n$ 则

$$\mathbf{Ax} = x_1 \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \end{bmatrix} + \cdots + x_n \begin{bmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{mn} \end{bmatrix} \quad \mathbf{a}_{\cdot 1}$$

mn 次乘法,
 $m(n-1)$ 次加法
 $O(mn)$

\mathbf{Ax} 可看作矩阵 A 各列的线性组合 矩阵 A 的列数必须与 \mathbf{x} 的行数相同

令 $\mathbf{b} = \mathbf{Ax}$ 则列向量 \mathbf{b} 的第 i 个元素为 $b_i = \langle \mathbf{a}_{i\cdot}, \mathbf{x} \rangle = \sum_{j=1}^n a_{ij} x_j$

向量 \mathbf{b} 的第 i 个元素为矩阵 A 第 i 行与列向量 \mathbf{x} 的内积

矩阵计算及性质


□ 矩阵-矩阵乘积

给定 $A \in R^{m \times n}$ 和 $B \in R^{n \times p}$

$$AB = C = (c_{ij}) \in R^{m \times p}$$

$$c_{ij} = \sum_k^n a_{ik} b_{kj}$$

$$= \langle \mathbf{a}_{i.}, \mathbf{b}_{.j} \rangle, i = 1, \dots, n \quad j = 1, \dots, p$$



mnp 次乘法,
 $m(n-1)p$ 次加法
 $O(mnp)$

矩阵A的列数等于矩阵B的行数

$AB \in R^{m \times p}$ 矩阵乘积C的行数为A的行数,C的列数为B的列数

矩阵计算及性质

□ 矩阵乘法运算律

乘法结合律 $A \in R^{m \times n}, B \in R^{n \times p}, C \in R^{p \times q}$ 则 $A(BC) = (AB)C$

左分配律: $A, B \in R^{m \times n}, C \in R^{n \times p}$ 则 $(A+B)C = AC + BC$

右分配律: $A \in R^{m \times n}, B, C \in R^{n \times p}$ 则 $A(B+C) = AB + AC$

一般情况下 $AB \neq BA$

矩阵计算及性质

□ 转置

$$A^T = \begin{bmatrix} a_{11} & a_{21} & a_{31} & \cdots & a_{m1} \\ a_{12} & a_{22} & a_{32} & \cdots & a_{m2} \\ a_{13} & a_{23} & a_{33} & \cdots & a_{m3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & a_{3n} & \cdots & a_{mn} \end{bmatrix} \in R^{n \times m} \quad (A^T)^T = A$$

$$\mathbf{x}^T = [x_1 \quad x_2 \quad x_3 \quad \cdots \quad x_m] \in R^{1 \times m} \quad (\mathbf{x}^T)^T = \mathbf{x}$$

$$(AB)^T = B^T A^T \quad (A+B)^T = A^T + B^T \quad \begin{bmatrix} A & B \end{bmatrix}^T = \begin{bmatrix} A^T \\ B^T \end{bmatrix}$$

矩阵计算及性质

□ 特殊类型矩阵

下矩阵

$$L = \begin{bmatrix} \ell_{11} & 0 & 0 & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix} \in R^{n \times n}$$

上矩阵

$$U = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{bmatrix} \in R^{n \times n}$$

矩阵计算及性质

□ 特殊类型矩阵

对角阵

$$D = \begin{bmatrix} d_{11} & 0 & 0 & 0 \\ 0 & d_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_{nn} \end{bmatrix} \in R^{n \times n}$$

单位阵

$$I = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in R^{n \times n}$$

对于任意对称矩阵 $A \in R^{n \times n}$

$$AI = IA = A$$

对称阵 当 $A^T = A$ 时, 称矩阵A为对称阵, 对称阵是方阵

矩阵计算及性质

□ 矩阵(方阵)的迹

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{bmatrix} \in R^{n \times n}$$

方阵A的迹为对角线元素之和

$$\text{tr}A = \sum_{i=1}^n a_{ii}$$

方阵迹的性质: $\text{tr}A = \text{tr}A^T$

$$A, B \in R^{n \times n}$$

$$A \in R^{n \times n}, \tau \in R$$

$$A \in R^{m \times n}, B \in R^{n \times m}, AB \in R^{m \times m}, BA \in R^{n \times n}$$

$$\text{tr}(A + B) = \text{tr}A + \text{tr}B$$

$$\text{tr}(\tau A) = \tau \text{tr}A$$

$$\text{tr}AB = \text{tr}BA$$

矩阵计算及性质

□ 向量的线性无关

为表示方便起见，将矩阵 A 表示为列向量形式

$A = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n]$ ，其中 $\mathbf{a}_j \in R^m$ 表示列向量，则前面提及的 $A\mathbf{x} = \mathbf{b}$

可写成标量与向量的乘积之和

$$\mathbf{a}_1 x_1 + \mathbf{a}_2 x_2 + \dots + \mathbf{a}_n x_n = \mathbf{b}$$

上式称为列向量 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$ 的线性组合

一组 m 维向量 $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ 构成的方程 $x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \dots + x_n \mathbf{a}_n = \mathbf{0}$

只有零解 $x_1 = x_2 = \dots = x_n = 0$ 则称向量组**线性无关**

否则称向量组**线性相关**

矩阵计算及性质

□ 空间概念

前面第18页讲了矩阵A的列空间,下面介绍线性代数中涉及到的其他空间相关概念:

以向量为元素的集合V称为向量空间

若 $S = \{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m\}$ 是向量空间V的向量子集合,则 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ 的所有线性组合的集合W称为由 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ 张成的子空间,定义为

$$W = \text{Span}\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m\} = \{\mathbf{u} \mid \mathbf{u} = a_1\mathbf{u}_1 + a_2\mathbf{u}_2 + \dots + a_m\mathbf{u}_m\}$$

矩阵计算及性质

□ 空间概念

在向量空间 W 中,如果存在 p 个($p \leq m$)向量 u_1, u_2, \dots, u_p 满足:

(1) u_1, u_2, \dots, u_p 线性无关

注意此处与上页比较 $p \leq m$

(2) W 中任一元素 u 总可由 u_1, u_2, \dots, u_p 线性表示

则 u_1, u_2, \dots, u_p 就称为向量空间 W 的一个基

子空间 W 的任何一组基的向量个数称为 W 的维数, $\dim(W)$

矩阵计算及性质

□ 矩阵的秩

设向量组 $A_0: a_1, a_2, \dots, a_r$ 是向量组 $A: a_1, a_2, \dots, a_n$ 的一部分 ($r \leq n$)

且满足:

(1) 向量组 A_0 线性无关

(2) 向量组 A 的任一向量都能由向量组 A_0 线性表示

则向量组 A_0 就是向量组 A 的一个最大线性无关组，最大线性无关组所含向量的个数 r 称为向量组 A 的秩

矩阵计算及性质

□ 矩阵的秩

给定 $A \in R^{m \times n}$, $x, b \in R^n$ 矩阵方程 $Ax = b$ 可分为三种类型:

(1) 适定方程: 若 $m=n$,且 $\text{rank}(A)=n$, 即矩阵 A 非奇异, 则称矩阵方程

$Ax = b$ 为适定(well-determined)方程. 方程解是唯一的 $x = A^{-1}b$

(2) 欠定方程: 若 $m < \text{rank}(A)$, 独立方程个数小于独立未知数个数

则称矩阵方程 $Ax = b$ 为欠定(under-determined)方程. 方程无穷多解

(3) 超定方程: 若 $m > \text{rank}(A)$, 独立方程个数大于独立未知数个数

则称矩阵方程 $Ax = b$ 为超定(over-determined)方程. 方程无精确解

矩阵计算及性质

□ 矩阵的秩

矩阵的秩定义为该矩阵中线性无关的列向量的数目

若 $\text{rank}(A) = r$ 则矩阵 A 有 r 个线性无关的列向量,这 r 个线性无关列向量的所有线性组合,便构成了一个向量空间,称为矩阵 A 的列空间 $\text{Col}(A)$

矩阵 A 的列空间 $\text{Col}(A)$ 的维数定义为该矩阵的秩, 即

$$r = \text{rank}(A) = \dim[\text{Col}(A)]$$

若矩阵 A 的秩为 r ,则该矩阵的列空间 $\text{Col}(A)$ 是一个 r 维子空间

矩阵计算及性质

□ 矩阵的秩

令 $r_A = \text{rank}(A), r_B = \text{rank}(B)$ 则乘积矩阵 AB 的秩具有下面性质:

$$\text{rank}(AB) = r_{AB} \leq \min\{r_A, r_B\}$$

矩阵 $A \in R^{m \times n}$ 左乘非奇异方阵 $P \in R^{m \times m}$ 或者右乘非奇异方阵 $Q \in R^{n \times n}$ 将不改变 A 的秩

$$\text{rank}(A+B) \leq \text{rank}([A, B]) \leq \text{rank}(A) + \text{rank}(B)$$

矩阵计算及性质

□ 可逆与非奇异

给定 $n \times n$ 方阵 A , 若存在一个 $n \times n$ 方阵 B 满足: $AB = BA = I$

则称方阵 A 是可逆的(或非奇异的), 方阵 B 称为 A 的逆矩阵, 记为 A^{-1}

n 阶方阵 A 是可逆的 $\Leftrightarrow n$ 阶方阵 A 是非奇异的 $\Leftrightarrow \text{rank}(A) = n$

$\Leftrightarrow \det(A) \neq 0$

n 阶方阵 A 的逆矩阵具有以下性质: A^{-1} 是唯一的 $\det(A^{-1}) = \frac{1}{\det(A)}$

$AA^{-1} = A^{-1}A = I$ A 为正交矩阵 $\Leftrightarrow A^{-1} = A^T$

$(A^{-1})^{-1} = A$ $(A^{-1})^T = (A^T)^{-1}$ $(AB)^{-1} = B^{-1}A^{-1}$

若 $A = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ 则 $A^{-1} = \text{diag}(a_{11}^{-1}, a_{22}^{-1}, \dots, a_{nn}^{-1})$

矩阵计算及性质

□ 方阵的特征值和特征向量

设 n 阶方阵 A ,如果数 λ 和 n 维列向量 \mathbf{x} 满足

$$A\mathbf{x} = \lambda\mathbf{x}$$

则这样的数 λ 称为方阵 A 的特征值,非零向量 \mathbf{x} 称为方阵 A 的对应于特征值 λ 的特征向量.

$A\mathbf{x} = \lambda\mathbf{x} \Leftrightarrow (A - \lambda I)\mathbf{x} = \mathbf{0}$ 存在非零解 $\mathbf{x} \neq \mathbf{0}$ 的唯一条件是矩阵 $A - \lambda I$ 的行列式等于零,即 $\det(A - \lambda I) = 0 \Leftrightarrow A - \lambda I$ 方阵奇异

设 n 阶矩阵 $A = (a_{ij})$ 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$,具备下列性质:

(1) $\lambda_1 + \lambda_2 + \dots + \lambda_n = a_{11} + a_{22} + \dots + a_{nn}$

(2) $\lambda_1 \lambda_2 \cdots \lambda_n = \det(A)$

矩阵计算及性质

□ 方阵的特征值和特征向量

- (3) 方阵 A 奇异,则其特征值至少有一个为0
- (4) 方阵 A 与 A^T 具有相同的特征值
- (5) λ 是方阵 A 的特征值,则 λ 也是 A^T 的特征值
- (6) λ 是方阵 A 的特征值,则 $\lambda + \sigma^2$ 是 $A + \sigma^2 I$ 的特征值
- (7) $\lambda (\neq 0)$ 是方阵 A 的特征值,则 $1/\lambda$ 是 A^{-1} 的特征值

矩阵计算及性质

□ 相似矩阵

两个 n 阶方阵 A 和 B 为相似矩阵当且仅当存在一个 n 阶可逆方阵 P 使得

$$P^{-1}AP = B$$

方阵 P 称为 A 与 B 之间的相似变换矩阵, 方阵 A 相似 B 记做: $A \sim B$

相似矩阵的性质:

$$A \sim A$$

$$A \sim B \Leftrightarrow B \sim A$$

$$A \sim B \Rightarrow \text{rank}(A) = \text{rank}(B), \det(A) = \det(B), \text{tr}(A) = \text{tr}(B)$$

$A \sim B \Rightarrow A$ 与 B 特征值相同, 特征向量未必相同

A 与对角阵相似, 则称 A 为可对角化矩阵

n 阶矩阵 A 与对角矩阵相似的充分必要条件为矩阵 A 有 n 个线性无关的特征向量

矩阵计算及性质

□ 矩阵的等价、相似与合同

矩阵等价: $A, B \in R^{m \times n}$ 如果两矩阵满足 $Q^{-1}AP = B$

其中, P 是 n 阶可逆方阵, Q 是 m 阶可逆方阵

两个同型矩阵 A 与 B 当且仅当他们秩相同的时候, 两个矩阵是等价的

矩阵合同: 设 A, B 均为 n 阶方阵, 若存在 n 阶可逆矩阵 C 使得 $C^T AC = B$

则称方阵 A 与 B 合同, 记做 $A \simeq B$

矩阵计算及性质

□ 二次型

n 阶实对称阵 A 的二次型定义为 $f = \mathbf{x}^T A \mathbf{x}$

对称阵 A 叫做二次型 f 的矩阵, f 叫做对称阵 A 的二次型

任给一个二次型就能唯一地确定一个对称阵;反之任给一个对称阵也能唯一确定一个二次型

□ 正定、半正定矩阵

对于 n 阶对称方阵 A

正定矩阵: 二次型 $\mathbf{x}^T A \mathbf{x} > 0, \forall \mathbf{x} \neq \mathbf{0}$ (对称方阵 A 所有特征值均为正数)

半正定矩阵: 二次型 $\mathbf{x}^T A \mathbf{x} \geq 0, \forall \mathbf{x} \neq \mathbf{0}$ (对称方阵 A 所有特征值均为非负数)

矩阵计算及性质

□ 向量的范数(vector norm)

$$\mathbf{x} \in R^n$$

$$\ell_1 \text{ 范数 } \|\mathbf{x}\|_1 = \sum_{j=1}^n |x_j|$$

$$\ell_2 \text{ 范数 } \|\mathbf{x}\|_2 = \left(x_1^2 + x_2^2 + \cdots + x_n^2 \right)^{\frac{1}{2}}$$

$$\ell_\infty \text{ 范数 } \|\mathbf{x}\|_\infty = \max(|x_1|, \dots, |x_n|) \quad \text{无穷范数}$$

$$\ell_p \text{ 范数 } \|\mathbf{x}\|_p = \left(\sum_{j=1}^n |x_j|^p \right)^{1/p}$$

矩阵计算及性质

□ 矩阵的范数(matrix norm)

$$A = (a_{ij}) \in R^{m \times n}$$

$$\text{F范数 } \|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2}$$

$$\ell_p \text{ 范数 } \|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p}$$

2范数(谱范数)

$\|A\|_2 = \sigma_{\max} = \sqrt{\lambda_{\max}}$, λ_{\max} 为 $A^T A$ 的最大特征值, σ_{\max} 为方阵 A 最大奇异值

$$\text{行和范数(无穷范数)} \quad \|A\|_{\infty} = \max_{1 \leq i \leq m} \left\{ \sum_{j=1}^n |a_{ij}| \right\}$$

矩阵范数的性质:

$$\|cA\| = |c| \|A\|$$

$$\|A + B\| \leq \|A\| + \|B\|$$

$$\|AB\| \leq \|A\| \|B\|$$



最小二乘法

□ 基本引导

给定数据对序列 $(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)$ 构建线性回归模型 $\hat{y} = kx + b$

残差(residual): $y_i - \hat{y}_i = y_i - (kx_i + b)$

SSE(sum squares of error): $SSE = \sum_{i=1}^m (y_i - \hat{y}_i)^2$



最小二乘法就是要求
使SSE最小的直线模型

$$\min \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

最小二乘法

$$\frac{\partial SSE}{\partial k} = 0$$

$$\frac{\partial SSE}{\partial b} = 0$$

$$SSE = \sum_{i=1}^m (y_i - \hat{y}_i)^2 = \sum_{i=1}^m (y_i - (kx_i + b))^2 = \sum_{i=1}^m (y_i - kx_i - b)^2$$

$$\frac{\partial SSE}{\partial b} = \frac{\partial \sum_{i=1}^m (y_i - kx_i - b)^2}{\partial b} = \sum_{i=1}^m 2(y_i - kx_i - b)(-1)$$

$$= \sum_{i=1}^m y_i - k \sum_{i=1}^m x_i - \sum_{i=1}^m b = \sum_{i=1}^m y_i - k \sum_{i=1}^m x_i - mb = 0$$

$$\Rightarrow b = \frac{1}{m} \sum_{i=1}^m y_i - k \frac{1}{m} \sum_{i=1}^m x_i = \bar{y} - k\bar{x}$$


(1) 直线偏移求解公式

$$\Rightarrow \bar{y} = k\bar{x} + b$$

表明 (\bar{x}, \bar{y}) 为直线 $\hat{y} = kx + b$ 上的点

最小二乘法

(\bar{x}, \bar{y}) 为直线 $\hat{y} = kx + b$ 上的点 $\Rightarrow k = \frac{\hat{y}_i - \bar{y}}{x_i - \bar{x}}$



最小二乘法

$$k = \frac{\hat{y}_i - \bar{y}}{x_i - \bar{x}} = \frac{(y_i - \bar{y}) - (y_i - \hat{y}_i)}{x_i - \bar{x}} \Rightarrow (y_i - \bar{y}) - (y_i - \hat{y}_i) = k(x_i - \bar{x})$$

$$\Rightarrow (y_i - \hat{y}_i) = (y_i - \bar{y}) - k(x_i - \bar{x}) \Rightarrow SSE = \sum_{i=1}^m (y_i - \hat{y}_i)^2 = \sum_{i=1}^m [(y_i - \bar{y}) - k(x_i - \bar{x})]^2$$

$$\frac{\partial SSE}{\partial k} = \frac{\partial \sum_{i=1}^m [(y_i - \bar{y}) - k(x_i - \bar{x})]^2}{\partial k} = -2 \sum_{i=1}^m [(y_i - \bar{y}) - k(x_i - \bar{x})](x_i - \bar{x}) = 0$$

$$\Rightarrow \sum_{i=1}^m (y_i - \bar{y})(x_i - \bar{x}) - k \sum_{i=1}^m (x_i - \bar{x})^2 = 0 \Rightarrow k = \frac{\sum_{i=1}^m (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^m (x_i - \bar{x})^2}$$

最小二乘法

□ 如何找到使得SSE最小的直线(线性回归模型)

给定数据对序列 $(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)$ 构建线性回归模型 $\hat{y} = kx + b$

Step1 根据已有数据求解平均值 \bar{x}, \bar{y}

Step2 根据已有数据和已计算的平均值求直线斜率

$$k = \frac{\sum_{i=1}^m (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^m (x_i - \bar{x})^2}$$

Step3 根据平均值和斜率计算偏移 $b = \bar{y} - k\bar{x}$

最小二乘法

□ 最小二乘法与最大似然法之间的联系

最小二乘法是残差满足正态分布情况下的最大似然估计

$$\varepsilon_i = y_i - \hat{y}_i = y_i - (kx_i + b) \quad y_i = (kx_i + b) + \varepsilon_i$$

令残差(residual)服从正态分布 $\varepsilon_i \sim N(0, \sigma^2)$,则残差的概率密度函数如下

$$f(\varepsilon_i | k, b) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\varepsilon_i^2}{2\sigma^2}\right) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \hat{y}_i)^2}{2\sigma^2}\right)$$

进而定义似然函数

$$L(k, b, \varepsilon_1, \varepsilon_2, \dots, \varepsilon_m) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \hat{y}_i)^2}{2\sigma^2}\right)$$

最小二乘法

□ 最小二乘法与最大似然法之间的联系

对数似然函数 $\ell(k, b, \varepsilon_1, \varepsilon_2, \dots, \varepsilon_m) = \ln L(k, b, \varepsilon_1, \varepsilon_2, \dots, \varepsilon_m)$

$$= \underbrace{\sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi\sigma}}}_{\text{constant}} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

最大似然函数 $\max \ell(k, b, \varepsilon_1, \varepsilon_2, \dots, \varepsilon_m) \Leftrightarrow \min \sum_{i=1}^m (y_i - \hat{y}_i)^2$

最大似然估计等价于最小二乘

最小二乘法

□ 几何意义前导——矩阵列空间

矩阵 $A \in R^{m \times n}$ 的列空间 $\text{Col}(A)$ 是 A 阵列向量所有线性组合的集合

如果 $A = [a_1, a_2, \dots, a_n]$ 则列空间 $\text{Col}(A)$ 可表示为

$$\text{Col}(A) = \text{Span}\{a_1, a_2, \dots, a_n\}$$

在列空间 $\text{Col}(A)$ 中的任一向量可以写成 Ax , 因为 Ax 表示矩阵 A 的列向量的线性组合

$$\text{Col}(A) = \{b \mid b = Ax, \forall x \in R^n\}$$

最小二乘法


□ 几何意义以及矩阵形式求解

线性方程组的矩阵形式 $A\mathbf{x} = \mathbf{y}$ 实际应用中,很难找到"极端精确"的方程解 $A\mathbf{x}$ 可认为是 \mathbf{y} 的近似解, 矩阵形式的最小二乘问题定义如下:

给定 $A \in R^{m \times n}$, $\mathbf{y} \in R^m$, 求方程组 $A\mathbf{x} = \mathbf{y}$ 的最小二乘解就是找到满足下面不等式的向量 $\hat{\mathbf{x}} \in R^n$

$$\|\mathbf{y} - A\hat{\mathbf{x}}\| \leq \|\mathbf{y} - A\mathbf{x}\|, \forall \mathbf{x} \in R^n$$

$\forall \mathbf{x} \in R^n$, $A\mathbf{x}$ 都是列空间 $\text{Col}(A)$ 中的点, 最小二乘法就是找到合适的 \mathbf{x} 使得 $A\mathbf{x}$ 成为列空间 $\text{Col}(A)$ 中距离 \mathbf{y} 最近的点



最小二乘法

线性方程 $A\mathbf{x} = \mathbf{y}$ 的最小二乘解与法方程 $A^T A\mathbf{x} = A^T \mathbf{y}$ 的解一致

当且仅当矩阵 A 的列线性无关(即列满秩)时, 方阵 $A^T A$ 可逆

当方阵 $A^T A$ 可逆时, 方程 $A\mathbf{x} = \mathbf{y}$ 有唯一的最小二乘解:

$$\hat{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{y}$$

最小二乘解是一种近似解, $A\hat{\mathbf{x}} = \hat{\mathbf{y}}$ 是对 \mathbf{y} 的一种逼近, 最小二乘误差 $\|\mathbf{y} - A\hat{\mathbf{x}}\|$ 用来衡量逼近效果

作业

- 参考下面链接，了解python (numpy)与今天讲到的线代和矩阵相关概念
- 参考链接：
 - <https://github.com/scalanlp/breeze/wiki/Linear-Algebra-Cheat-Sheet>
 - <https://docs.scipy.org/doc/numpy-1.13.0/reference/routines.linalg.html>
 - <http://blog.csdn.net/airfish20000/article/details/60880932>
 - <http://blog.csdn.net/bitcarmanlee/article/details/51945271>

感谢大家！

恳请大家批评指正！